

Rapport de synthèse - Semaines 1 & 2 : Nettoyage & EDA

Dataset : Films & Séries Netflix · AnalystLab Africa - Data Analytics Internship (Batch C)

1. Difficultés rencontrées lors du nettoyage

- **30 % de réalisateurs manquants (2 634 lignes), plus 825 castings et 831 pays.** Contrairement au dataset e-commerce, supprimer ces lignes aurait détruit un tiers du catalogue pour des champs purement descriptifs : elles ont été **imputées par "Unknown"** et exclues au cas par cas des analyses concernées.
- **3 lignes décalées.** Trois films (spectacles de Louis C.K.) avaient leur durée ("74 min"...) stockée dans la colonne rating et une durée vide - une erreur de saisie à la source, corrigée en remplaçant les valeurs dans la bonne colonne.
- **Colonne duration à unités mixtes.** Minutes pour les films, saisons pour les séries : impossible à analyser telle quelle. Elle a été scindée en une valeur numérique et une unité.
- **88 dates avec espace parasite** en début de chaîne, qui faisaient échouer la conversion en datetime sans un `.str.strip()` préalable.
- **Champs multi-valeurs** (country, listed_in) : plusieurs pays ou genres par ligne, séparés par des virgules - nécessite un `split + explode` avant tout comptage.

Bilan : 8 807 lignes conservées sur 8 807 (0 suppression) - un nettoyage par correction et structuration, sans perte.

2. Principales conclusions de l'EDA

- Catalogue au 25/09/2021 : 8 807 titres, 6 131 films (69,6 %) et 2 676 séries (30,4 %).
- Films : durée médiane de 98 minutes (de 3 à 312 min). Séries : 67 % n'ont qu'une saison.
- Ajouts au catalogue : pic en 2019 (~2 000 titres), repli en 2020-2021.
- Production : États-Unis (3 689 titres), Inde (1 046), Royaume-Uni (804) en tête.

3. Insights majeurs

1. **Croissance stoppée par la pandémie** : après une explosion 2016-2019, les ajouts reculent nettement en 2020-2021 - l'impact du COVID sur la production mondiale est directement lisible dans les données.
2. **Mondialisation en marche** : les États-Unis dominent encore, mais le premier genre du catalogue est « International Movies » (2 752 titres) et l'Inde est déjà le 2e pays producteur.
3. **Positionnement adulte assumé** : 61 % des titres sont classés TV-MA ou TV-14 ; le contenu familial est minoritaire.
4. **Stratégie séries en flux** : les deux tiers des séries n'ont qu'une saison - beaucoup de tests de concepts et de renouvellement permanent plutôt que de longues franchises.

4. Livrables associés

Fichier	Contenu
netflix_titles_clean.csv	Dataset nettoyé et enrichi (8 807 lignes, 15 colonnes)
Semaine1-2_Netflix_EDA.ipynb	Notebook complet (compréhension, nettoyage, EDA, 6 visualisations, insights)
visualisations/viz1...viz6 (.png)	Visualisations exportées